

TP3 : Les statistiques descriptives avec python (Suite) et Choix des axes factoriels

"Les iris de Fisher" sont des données proposées en 1933 par le statisticien Ronald Aylmer Fisher comme données de référence pour l'analyse de données.

Les données correspondent à 3 espèces de fleurs (Iris setosa, Iris virginica, Iris versicolor). En tout nous avons un échantillon de 150 fleurs (50 fleurs de chaque espèce). Les variables mesurées sur ces fleurs sont : la longueur et la largeur des sépales (SE_L et SE_W), la longueur et la largeur des pétales (PE_L et PE_W). Toutes ces variables sont exprimées en millimètres.



Iris Setosa



Iris Versicolor



Iris Virginica

1. Chargement des données et structure Data.frame

Importez le fichier « IRIS.xlsx » dans un Data.frame.

2. Description des données

- Combien y a-t-il d'individus et de variables dans le fichier ? Notez bien les noms des variables.
- Affichez les statistiques élémentaires concernant l'ensemble de données importées (describe).
- Affichez les statistiques élémentaires pour chacune des espèces.
- Que peut-on dire de la distribution de chaque variable, en observant la moyenne et l'écart-type ?

3. Graphiques

- Il faut importer matplotlib pour la réalisation des graphiques.
- Afficher l'histogramme d'une variable ainsi que sa densité.
- Afficher l'histogramme d'une variable ainsi que sa densité pour chaque espèce.
- Comparer les distributions des différentes espèces avec un boxplot.
- Tracer le nuage de points individus pour deux variables.
- Tracer la matrice des nuages de points individus pour toutes les variables deux à deux.

4. Choix des axes factoriels

- Calculer la matrice de corrélation et confirmer les résultats de la question précédente.
- Calculer les valeurs et vecteurs propres
- Calculer et afficher les valeurs et vecteurs propres de la matrice de corrélation.
- Que représente chaque valeur propre?
- Pourquoi la matrice de corrélation est diagonalisable ? Peut-on avoir un vecteur propre nul ou une valeur propre nulle ? Pourquoi ?

- Calculer le pourcentage de variance expliquée par chacun des axes factoriels. En déduire la dimension du s.e.v (sous-espace vectoriel) de projection. Dites pourquoi ce résultat était prévisible ?
- Quelle est la relation de corrélation entre les deux composantes principales ?

5. Coordonnées des individus sur les axes principaux

- Calculer les coordonnées de la fleur de code " i027_VIRGINICA" sur les deux premiers axes factoriels.
- Quel est la fleur qui a contribué le plus au positionnement du premier axe.
- Que pouvez-vous dire de la qualité de représentation de l'échantillon des fleurs sur le premier plan factoriel.
- Calculer la qualité de représentation de la fleur de code "i027_VIRGINICA" sur les deux premiers axes factoriels.
- Dessiner le cercle de corrélation et la projection des 4 variables sur le premier plan factoriel.
- Comment interpréter les deux premiers axes de l'ACP ?
- D'après ces derniers résultats, déterminer des caractéristiques discriminantes des trois espèces de fleurs (Iris setosa, Iris virginica, Iris versicolor).